

# Análise de código e eficiência do método do Gradiente

Aryane Ast dos Santos  
Kevin Katzer

23 de novembro de 2014

## Sumário

<b>1</b>	<b>Introdução</b>	<b>2</b>
<b>2</b>	<b>Verificação de uso de memória com Valgrind</b>	<b>2</b>
<b>3</b>	<b>Arquitetura do computador</b>	<b>2</b>
<b>4</b>	<b>Comparação de desempenho geral</b>	<b>3</b>
<b>5</b>	<b>Análise dos cálculos do fator lambda e resíduo</b>	<b>4</b>
5.1	Medidas de operações em ponto flutuante, memória utilizada e cache misses	4
5.2	Melhoria no código . . . . .	11
5.3	Total de operações em ponto flutuante de dupla precisão . . . . .	12
5.4	Utilização de memória . . . . .	12

# 1 Introdução

Este trabalho consiste na análise e otimização da implementação do método do gradiente apresentado anteriormente. Compara tempo de execução, uso de cache, memória e Flops entre versões com e sem otimização.

Porém, como a otimização não saiu conforme o planejado, e o desempenho não melhorou, o trabalho teve que ser entregue sem a análise dos gráficos após a otimização. Não obstante, os códigos otimizados foram mantidos para avaliação do professor no momento da apresentação do trabalho.

## 2 Verificação de uso de memória com Valgrind

Ao executar a ferramenta Valgrind para se obter informações sobre vazamento de memória no programa gradSolver, foi possível observar 5 erros, todos em contextos diferentes, além de 16 alocações e apenas 2 liberações de memória.

Os resultados da execução do programa são parcialmente apresentados na figura 1.

```
==29599== Command: ./gradSolver -r 5
==28949== HEAP SUMMARY:
==28949== in use at exit: 560 bytes in 14 blocks
==28949== total heap usage: 16 allocs, 2 frees, 800 bytes allocated
==28949== LEAK SUMMARY:
==28949== definitely lost: 560 bytes in 14 blocks
==28949== ERROR SUMMARY: 5 errors from 5 contexts (suppressed: 0 from 0)
```

Figura 1: Saída do Valgrind

Aqui o gradSolver foi executado com uma matriz quadrada de ordem 5, porém os mesmos problemas listados na figura 1 são encontrados em execuções de matrizes de qualquer dimensão. E de maneira análoga, ao resolver os problemas apresentados, numa execução com matriz maior, eles ficam também automaticamente resolvidos.

Para contornar os vazamentos de memória encontrados, foi necessário liberar a memória dos vetores alocados explicitamente como o vetor x na função main, o vetor aux em calcGrad e o vetor r de resíduo na função gradSolver. Além disso, no main, foram adicionados frees para os ponteiros para char das flags do getopt.

## 3 Arquitetura do computador

Utilizando a ferramenta likwid-topology, é possível obter as seguintes informações sobre a arquitetura do computador utilizado para os testes de performance.

CPU type: AMD Magny Cours processor	NUMA Topology
Hardware Thread Topology	NUMA domains: 2
Sockets: 4	Domain 0:
Cores per socket: 8	Processors: 0 1 2 3 4 5 12 13 14 15 16 17
Threads per core: 1	Relative distance to nodes: 10 21
Socket 0: ( 0 1 2 3 4 5 6 7 )	Memory: 2403.31MB free of total 24103.8MB

Cache Topology	Level: 2	Level: 3
Level: 1	Size: 512 kB	Size: 5 MB
Size: 64 kB	Type: Unified cache	Type: Unified cache
Type: Data cache	Associativity: 16	Associativity: 96
Associativity: 2	Number of sets: 512	Number of sets: 512
Number of sets: 512	Cache line size:64	Cache line size:64
Cache line size:64	Non Inclusive cache	Non Inclusive cache
Non Inclusive cache	Shared among 1 threads	Shared among 4 threads
Shared among 1 threads		

Figura 2: Saída resumida do likwid-topology

Como pode-se notar na figura 2, nas servidoras do DInf, há uma CPU Magny Cours, fabricada pela AMD, com 4 socket e 32 cores (8 por socket).

Existem 3 níveis de cache, sendo o primeiro (L1) com 64kB de memória, o segundo (L2) com 512kB e o terceiro (L3) com 5MB. As caches L1 e L2 são separadas em 32 grupos, sendo que cada grupo é destinado a um core diferente, e o último nível de cache, L3, é separado em 8 grupos, cada grupo destinado a 4 cores.

Há 8 domínios NUMA, e cada domínio correspondendo a uma cache L3. Como apenas o Socket 0 será usado, apenas o primeiro domínio NUMA é de interesse para análise de memória disponível. O domínio 0 possui 16047.3MB de memória RAM, e no momento de execução do likwid-topology, havia 10269.2MB de memória livre.

Dada a especificação acima, o maior sistema linear passível de ser resolvido pela arquitetura descrita é aproximadamente 36600, pois, dada a memória RAM disponível, e sabendo que o programa aloca  $n^2 + 3n$  doubles, temos que  $64(n^2 + 3n) = 10269.2 \times 2^{23}$ .

## 4 Comparação de desempenho geral

Para a execução dos testes de desempenho, foi utilizada a ferramenta likwid-pin, que afixa a execução do programa à um core da máquina em uso dedicado. Mas como a cache L3 continua sendo compartilhada, analisar o desempenho de diferentes execuções se torna um problema, pois é necessário minimizar o uso da cache pelos outros programas. Uma solução encontrada foi executar o gradSolver em mode single user, porém não foi possível utilizar a

solução com os testes apresentados. Vale notar que no período de testes não haviam outros usuários logados na máquina.

No gráfico 3, são mostrados os tempos de execução em segundos, que foram obtidos com a função timestamp, para matrizes de dimensões 32, 256, 1024 e 2048. Na escala horizontal do gráfico, as diferenças entre as potências de 2 e  $2^n + 1$  não aparecem claramente. Os eixos do gráfico estão em escala logarítmica.

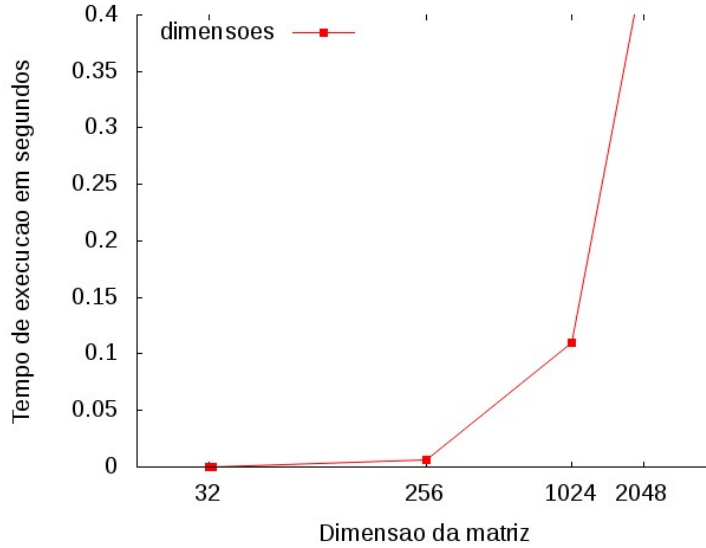


Figura 3: Tempo de execução por dimensão da matriz

Em teoria, as execuções do gradSolver com matrizes de dimensões que não são potência de 2 seriam ligeiramente melhores, por causa de um melhor uso da associatividade da cache. Porém, isso não pode ser verificado nas execuções para os tamanhos de cache exibidos acima. Uma melhor visualização dos tempos de execução pode ser observado na tabela 4, onde a primeira coluna são as dimensões da matriz e a segunda os tempos de execução de 50 iterações do método do gradiente em segundos.

## 5 Análise dos cálculos do fator lambda e resíduo

### 5.1 Medidas de operações em ponto flutuante, memória utilizada e cache misses

Utilizando a ferramenta likwid-perfctr, foi possível obter informações nos trechos de código referentes ao cálculo do fator lambda e do resíduo sobre memória, cache e operações em ponto flutuante de dupla precisão.

```

32 0.00014233589172363
33 0.00027585029602051
256 0.00672078132629395
257 0.00610208511352539
1024 0.10956859588623047
1025 0.10990786552429199
2048 0.43970751762390137
2049 0.43948912620544434

```

Figura 4: Tempo de execução por dimensão da matriz




Figura 5: Taxa de falta na cache na função lambda por dimensão da matriz

Nos gráficos a seguir, as linhas pretas representam a compilação normal e a vermelha a compilação otimizada com -O3.

Nos gráficos nas figuras 5 e 6 podem ser observadas o total de faltas na cache para uma iteração das funções Lambda e Resíduo.

Explicação cache...




Figura 6: Taxa de falta na cache na função de resíduo por dimensão da matriz

Já nas figuras 7 e 8, estão descritas a quantidade de MBytes/s por dimensão da matriz utilizadas em uma iteração das funções de cálculo de lambda e resíduo.

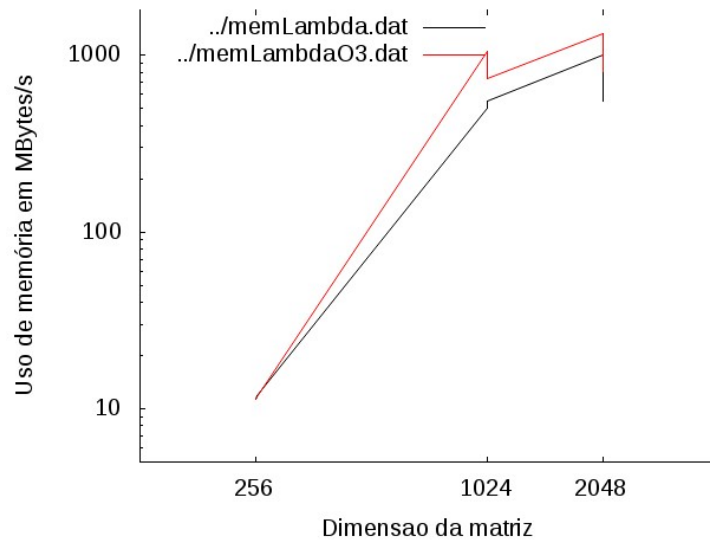


Figura 7: Uso de memória em MBytes/s por dimensão da matriz

A vazão de memória aumenta nas versões otimizadas, pois como várias partes da memória são acessadas ao mesmo tempo através da vetorização, as operações em ponto flutuante são efetuadas mais rapidamente.




Figura 8: Uso de memória em MBytes/s por dimensão da matriz



E por fim, nas figuras 9 e 10 encontram-se a quantidade de MFlops/s em relação às dimensões da matriz para uma iteração dos cálculos de lambda e resíduo.




Figura 9: MFlops/s por dimensão da matriz no cálculo de lambda

O número de operações em ponto flutuante por segundo também aumenta a medida que o  $n$  aumenta pois há mais operações a serem feitas em menos tempo. Porém, quando  $n$  alcança um certo ponto, o número de flops diminui, já que o processador só consegue fazer um determinado número de operações em um dado tempo, e a partir daí as requisições ao processador começam a ter que entrar em fila e a latência do processador passa a ser um problema. A otimização não ajuda muito nesse aspecto, pois é uma limitação de hardware.

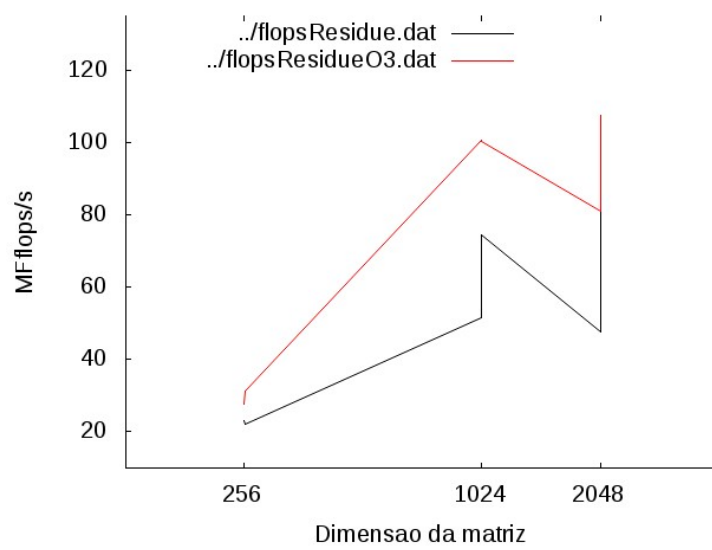


Figura 10: MFlops/s por dimensão da matriz no cálculo do resíduo

## 5.2 Melhoria no código

Como melhoria do código foi realizado um merge dos laços da multiplicação de matrizes, e duas multiplicações de vetores, de forma que onde antes se tinha  $2n^2 + 4n$  flops agora se tem ..., como é possível verificar no gráfico abaixo.

Apesar da quantidade de cache miss não diminuir consideravelmente com compilação -O3, o desempenho em segundos melhora significativamente, como mostra a figura 11, que traça uma comparação das compilações normal, com otimização -O3 e com a melhoria do código para x iterações.




Figura 11: Desempenho em segundos compilação normal X compilação otimizada

Linha de tal cor representa tal.

### 5.3 Total de operações em ponto flutuante de dupla precisão

Na função `multMat`, há duas operações em ponto flutuante dentro de dois laços aninhados, e como as duas operações são uma soma e multiplicação juntas, conta-se apenas uma operação. Na função linear `multVet`, há duas operações de doubles dentro de apenas um laço. Como a função `lambda` utiliza duas vezes a função `multVet` e uma vez a função `multMat`, a função que descreve flops em função de  $n$  é dada por, aproximadamente,  $f(n) = 2n^2 + 4n$ . Esse valor pode variar com as otimizações introduzidas pelo compilador.

Para obter esses valores, se utiliza o `likwid-perfctr` medindo o grupo `FLOPS_DP`. Basta multiplicar o valor em MFlops/s pelo tempo em segundos e então por  $2^{20}$ . Assim se obtém o total absoluto de flops utilizados por trecho de código.

Não foi possível fazer um casamento da complexidade em função da dimensão da matriz com a conta que se faz com os valores do `likwid`, pois saída do `likwid-perfctr` para `FLOPS_DP` sofre muitas variações. Aí seria necessário ler a documentação da ferramenta para descobrir se o programa pega os valores por amostragem de código em execução. Assumindo isso, os valores ficariam mais próximos aos reais a partir de uma amostragem maior de código, e no caso apresentado, a medição leva em conta apenas uma iteração do cálculo do `lambda`.

O mesmo vale para o cálculo do resíduo, que é descrito pela função  $f(n) = 2n^2$ .

### 5.4 Utilização de memória

Nos gráficos 7 e 8 percebe-se que o uso de memória aumenta em função de  $N$ , sendo  $N$  a dimensão da matriz de entrada do `gradSolver`. Na função `lambda`, há acessos de memória nas funções de multiplicação de matrizes e na de vetores, `multMat` e `multVet`. Na `multMat` existem dois laços aninhados contendo 3 acessos à memória, e na função `multVet` há 2 acessos à memória e a mesma é invocada duas vezes. Juntando tudo isso, a função `lambda` utiliza  $f(n) = 3n^2 + 4n$  doubles de memória, lembrando que cada double possui 8 bytes.

Na mesma linha de raciocínio, a quantidade de memória utilizada pela função de resíduo é dada por  $f(n) = 5n^2$  doubles.

Para verificar os resultados, o mesmo raciocínio feito para descobrir a quantidade de flops num trecho vale: multiplica-se MBytes/s pelo tempo de execução, ambas informações coletadas do `likwid-perfctr` aplicado ao grupo `MEM`, e então por  $2^{20}$  para se obter a quantia em bytes utilizada pela função.